

Causal Machine Learning

Project Proposal

1. Group Identification

Name	Email	Student ID
Eduardo Assis Tomich	eduardoatomich@gmail.com	2020006485
Lucas Augusto da Silva Gonçalves	lucasaugusto83.la@gmail.com	2019006884
Lucas Vitor da Silva Ramos	-	2021085460
Rafael Vinícius dos Santos	rafaelsantos@dcc.ufmg.br	2026693476

2. Definição do Problema

Contexto do domínio: No setor de telecomunicações, o custo de aquisição (CAC) supera significativamente o de retenção, tornando o *churn* um desafio crítico para a receita. Embora modelos preditivos tradicionais identifiquem clientes com alto risco de cancelamento, eles não prescrevem a ação ideal. Intervenções de retenção possuem custos operacionais e, sem uma abordagem causal, a empresa corre o risco de desperdiçar recursos com clientes que permaneceriam de qualquer forma ou que sairão independentemente do incentivo.

O problema de *Unit Selection*: Para otimizar o retorno sobre investimento (*ROI*), é necessário transitar da predição de desfechos para a avaliação de comportamentos contrafatuais. Utilizando o framework de Pearl, classificamos a população em quatro estratos causais:

- **Always-takers:** Clientes que permanecerão independentemente do incentivo.
- **Never-takers:** Clientes que cancelarão mesmo se receberem o benefício.
- **Defiers:** Clientes que cancelariam especificamente por causa da intervenção.
- **Compliers:** Clientes que só permanecerão se receberem o tratamento.

Relevância: O projeto visa otimizar a política de retenção identificando estritamente os "Compliers" para cada tipo de intervenção. Ao formular a prevenção de churn como um problema de *Unit Selection* multi-tratamento, aplicaremos Aprendizado de Máquina Causal para garantir que incentivos específicos (como Suporte Técnico ou Serviços de Streaming) sejam oferecidos apenas quando forem a causa direta da permanência do cliente, maximizando o ROI e a eficiência da alocação de recursos.

3. Formulação do Problema de Machine Learning

O problema de negócio transcende a classificação binária tradicional, que buscaria apenas estimar o risco basal do cliente cancelar a assinatura ($P(Y | C)$). Para viabilizar o *Unit Selection*, formulamos este projeto como uma tarefa de **Estimação de Efeito de Tratamento (Treatment Effect Estimation)** baseada em dados observacionais, culminando em um problema de otimização de decisão.

As variáveis fundamentais que mapeiam o problema são definidas da seguinte forma:

- **Features de Entrada / Covariáveis (C):** Conjunto de atributos observáveis de cada cliente antes da atribuição do tratamento. Isso inclui dados demográficos (*gender*, *SeniorCitizen*), informações da conta (*tenure*, *Contract*, *MonthlyCharges*) e serviços contratados previamente (*InternetService*, *OnlineSecurity*, etc.).
- **Variáveis de Tratamento (X):** Representam as diferentes intervenções possíveis. Em vez de uma variável única, consideraremos um vetor de tratamentos onde cada $X_k \in \{\text{TechSupport, StreamingTV, StreamingMovies}\}$. Isso nos permite avaliar o efeito de cada serviço de forma isolada ou combinada.
- **Variável Alvo / Desfecho (Y):** A variável de interesse que queremos impactar positivamente. Utilizaremos a Retenção do cliente, que é a modelagem reversa da variável *Churn* do dataset ($Y = 1$ para "Ficou/No Churn", e $Y = 0$ para "Cancelou/Churn").

Mapeamento da Formulação ML: O objetivo é aprender o Efeito de Tratamento Condicional Médio (CATE) para cada possível intervenção x :

$$CATE_k(c) = \mathbb{E}[Y | do(X = x_k), C = c] - \mathbb{E}[Y | do(X = 0), C = c]$$

A partir dessas estimativas, o problema torna-se uma **Otimização de Política (Policy Optimization)**, onde o algoritmo não apenas decide se deve intervir, mas seleciona qual tratamento x_k apresenta a maior probabilidade de converter um cliente em "Complier" com o menor custo operacional.

4. Paradigma de Machine Learning

O Paradigma Selecionado foi o de Aprendizado Supervisionado integrado à Inferência Causal, dado que o projeto é baseado em um conjunto de dados observacionais históricos onde todas as variáveis de interesse estão devidamente rotuladas: conhecemos as covariáveis (C), quem possuía ou não os serviços especializados (X , Tratamento) e quem permaneceu ou cancelou a assinatura (Y , Desfecho).

Utilizaremos algoritmos de Aprendizado Supervisionado tradicionais (como regressão ou árvores de decisão) atuando como estimadores-base dentro de arquiteturas de *Meta-Learners* (como T-Learner ou X-Learner). Esse paradigma supervisionado é o mecanismo computacional necessário para prever os desfechos contrafatuais e ajustar os vieses de seleção dos dados observacionais, permitindo que o modelo extraia o efeito causal individual (CATE) em vez de meras correlações.

5. Datasets

O projeto utilizará o dataset *Telco Customer Churn*. Abaixo estão os detalhes fundamentais sobre os dados, alinhados com a formulação do problema causal:

- **Source and availability:** O conjunto de dados tem como origem a plataforma IBM Watson Analytics e possui disponibilidade pública (amplamente acessível para fins acadêmicos e práticos em repositórios como o Kaggle).
- **Number of instances and features:** O dataset é composto por 7.043 instâncias (linhas representando clientes individuais) e 21 atributos (colunas).
- **Key variables:**
 - *Treatments (X)*: Um conjunto de variáveis que representam as múltiplas intervenções (ofertas de retenção) possíveis da operadora. Em vez de avaliar um tratamento único, o projeto explorará o efeito causal de diferentes serviços adicionais, focando em atributos como **TechSupport**, **StreamingTV** e **StreamingMovies**. A análise simulará o impacto de atribuir cada um desses serviços (por exemplo, estimar a diferença entre $do(\text{TechSupport} = 1)$ e $do(\text{StreamingTV} = 1)$) para determinar qual intervenção específica maximiza a probabilidade de retenção para cada perfil de cliente.
 - *Outcome (Y)*: A variável **Churn**, que define o desfecho.
 - *Covariates/Confounders (C)*: Variáveis observadas que afetam tanto a probabilidade de o cliente ter o tratamento quanto a probabilidade do desfecho. As principais incluem **tenure** (tempo de casa), **MonthlyCharges** (encargos mensais), **Contract** (tipo de contrato), além de fatores demográficos (**gender**, **SeniorCitizen**, **Dependents**).
- **Data type:** Trata-se de um conjunto de dados estritamente observacional. Não houve um ensaio clínico randomizado (RCT) para a atribuição do serviço de suporte técnico.
- **Known limitations:**
 - *Desbalanceamento de Classes*: A variável alvo (**Churn**) apresenta um desbalanceamento significativo, com uma distribuição de aproximadamente 73% de clientes que permaneceram contra 27% que cancelaram. Esse desequilíbrio pode enviesar os modelos para a classe majoritária, exigindo o uso de métricas de avaliação robustas e técnicas de calibração para garantir que as probabilidades contrafatuais não sejam subestimadas para o grupo minoritário.
 - *Selection Bias (Viés de Seleção)*: Como os dados são observacionais, a análise baseia-se na premissa forte de desconfundimento (*Unconfoundedness*). Clientes que optaram por assinar serviços como o **TechSupport** podem apresentar características subjacentes (como maior estabilidade financeira) que enviesam a amostra. O modelo precisará ajustar essa autoseleção.
 - *Data Types e Missing Data*: Valores em formato incorreto exigirão pré-processamento, como a conversão de strings vazias em **TotalCharges** para valores numéricos em casos de clientes novos com **tenure** igual a zero.

6. Perguntas de Pesquisa

- RQ1. Estimação Causal Multi-Tratamento:** Qual é o efeito causal heterogêneo (CATE) da oferta de **TechSupport** em comparação com as opções de **Streaming** (TV ou Movies) na probabilidade de retenção de um cliente?
- RQ2. Otimização de Política (Unit Selection):** Em termos de Retorno sobre Investimento (ROI) simulado, qual é o ganho financeiro de alocar intervenções específicas estritamente aos *Compliers* de cada serviço, em contraste com a heurística tradicional de oferecer benefícios aleatórios a todos os clientes com alto risco preditivo de *churn*?
- RQ3. Heterogeneidade e Robustez:** Como as características de contrato e estabilidade (notadamente **tenure** e **MonthlyCharges**) afetam a magnitude do efeito de cada tratamento, e quão robustas são essas estimativas causais frente ao desbalanceamento natural da classe alvo nos dados observacionais?

7. Nível na Hierarquia Causal de Pearl

Selected level: Nível 3 – Contrafactual (*Counterfactual*), operando sobre alicerces do Nível 2 (*Intervention*).

Justification:

A análise puramente associacional (Nível 1) é insuficiente, pois prediz apenas o risco preditivo de cancelamento, sem informar como o cliente reagiria a uma intervenção. Embora o cálculo do Efeito de Tratamento Condicional Médio (CATE) envolva a matemática de intervenção do Nível 2 ($P(Y \mid do(X))$), a formulação central deste projeto — a otimização de campanhas via *Unit Selection* — exige raciocínio estritamente posicionado no Nível 3 da hierarquia de Pearl.

Para classificar um indivíduo nos estratos propostos por Li & Pearl e focar estritamente na identificação dos *Compliers*, o modelo precisa estimar a probabilidade conjunta de eventos contrafatuais. Em outras palavras, é necessário responder a perguntas individualizadas no formato: "Dado um cliente com as características C que cancelaria a assinatura se não recebesse oferta alguma ($Y_{x=0} = 0$), qual é a probabilidade desse mesmo indivíduo permanecer na base caso lhe fosse oferecido o Suporte Técnico ($Y_{x=1} = 1$)?"

Essa modelagem de retrospecção individual (*what-if reasoning*) transcende a simples avaliação média de políticas do Nível 2. A resposta para as nossas Questões de Pesquisa — especificamente a maximização do ROI — depende diretamente da extração dos limites (*bounds*) probabilísticos dessas variáveis contrafatuais cruzadas, garantindo que a intervenção seja direcionada cirurgicamente para clientes que só permanecerão *por causa* do tratamento.

8. Causal Inference Techniques and Concepts

1. *Ajuste Observacional (Backdoor Adjustment)*: Utilizaremos Propensity Score Matching (PSM) ou Inverse Probability Weighting (IPW) para balancear a base e quebrar a associação espúria entre X e C , permitindo estimar $P(Y|do(X))$.
2. *Meta-Learners*: Modelos como T-Learner ou X-Learner (usando XGBoost como estimador base) para prever o CATE a nível individual.
3. *Unit Selection (Lógica Contrafactual)*: Aplicação das equações de Li & Pearl (2022) para injetar o SCM (Modelo Causal Estrutural) derivado dos dados. Definiremos pesos hipotéticos de negócio (Ex: Lucro de reter = \$500; Custo de oferecer o suporte = \$50; Custo do Defier = -\$600) para otimizar a seleção dos alvos da campanha.

9. Métricas de Avaliação

Para garantir uma avaliação robusta que responda às Questões de Pesquisa (RQs) e lide com o desbalanceamento inerente aos dados, adotaremos um conjunto triplo de métricas: predição base, inferência causal e impacto de negócio.

1. Métricas de Desempenho Preditivo (Estimadores-Base)

- **PR-AUC (Precision-Recall Area Under Curve)**: Devido ao severo desbalanceamento da classe alvo (73% Retenção vs. 27% Churn), o PR-AUC é preferível ao tradicional ROC-AUC. Ele foca na classe minoritária, garantindo que a previsão do desfecho factual (Y) não esteja sendo inflada pela prevalência da classe majoritária (RQ3).
- **Brier Score**: Avalia a calibração das probabilidades previstas. Na inferência causal, prever probabilidades muito bem calibradas é mais importante do que apenas a acurácia de classificação, pois qualquer erro em $P(Y | X, C)$ se propaga no cálculo do CATE.

2. Métricas Específicas de Causalidade (Uplift e CATE)

- **AUUC (Area Under the Uplift Curve) e Qini Score**: Em dados estritamente observacionais, não possuímos o contrafactual real (ground truth) para calcular o PEHE (*Precision in Estimation of Heterogeneous Effect*). O AUUC contorna isso avaliando cumulativamente se o modelo consegue ordenar os clientes corretamente, priorizando aqueles em que a diferença de retenção

entre o grupo tratado e o controle é maior. Isso responderá qual intervenção (TechSupport vs. Streaming) tem melhor performance de ranqueamento causal (RQ1).

3. Métricas de Negócio e Política de Decisão

- **Expected ROI (Retorno sobre Investimento Simulado):** A métrica definitiva do *Unit Selection* (RQ2). Formularemos uma Função de Benefício atribuindo valores monetários (ex: Lucro ao reter = +\$500, Custo do serviço = -\$50, Custo do Defier = -\$600). O ROI simulado avaliará o lucro esperado da política causal em comparação a heurísticas ingênuas (como oferecer intervenções a qualquer cliente com probabilidade de *churn* > 70%).

10. Model Validation Strategy

Como lidamos com dados observacionais, a validação das premissas é a parte mais crítica do estudo:

- *Plausibilidade de Premissas:* Avaliação de Overlap (Positividade) plotando as distribuições dos propensity scores entre tratados e controles.
- *Testes de Refutação (Sensitivity Analysis):* Utilizaremos a biblioteca DoWhy (EconML) para rodar testes de robustez:
 - * *Placebo Treatment:* Substituir o TechSupport por uma variável aleatória. O efeito causal estimado deve cair para zero.
 - * *Unobserved Confounder:* Simular a introdução de uma variável oculta não medida para testar quão forte ela precisaria ser para invalidar nossas conclusões causais.

11. References

- [1] IBM Watson Analytics. Telco customer churn dataset. <https://www.kaggle.com/datasets/blastchar/telco-customer-churn>, 2015. Acessado em: 2024.
- [2] Ang Li and Judea Pearl. Unit selection based on counterfactual logic. In *Proceedings of the 28th International Joint Conference on Artificial Intelligence (IJCAI)*, pages 1793–1799. AAAI Press, 2019.
- [3] Ang Li and Judea Pearl. Unit selection with causal diagram. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 36, pages 5765–5772, 2022.
- [4] Amit Sharma and Emre Kiciman. Dowhy: an end-to-end library for causal inference. *arXiv preprint arXiv:2011.04216*, 2020.